

預期1.x在低多項式時間內在網格圖上進行跨度最優多智能體路徑查找

郭晶金於羅
格斯大學，新
澤西州立大學，美國新澤西州皮斯卡塔韋。

teng.guo@rutgers.edu
jingjin.yu@rutgers.edu

抽象的

多智能體路徑查找 (MAPF) 是 NP 難題，即使在圖上也難以最優求解，這表明沒有多項式時間演算法可以為其計算精確的最優解。這就提出了一個自然的問題：多項式時間演算法能達到多優？儘管已經開發出了計算常數因子最優解的演算法，但常數因子通常非常大，限制了它們的應用潛力。在這項工作中，除了其他突破之外，我們提出了第一個低多項式時間 MAPF 演算法，為隨機實例的 2D（分別為 3D）網格提供 1-1.5（分別為 1-1.67）漸近完工時間最適性保證。此外，當引入規則分佈的障礙時，我們的方法不會出現效能下降。這些方法概括為支持 100% 代理密度。

無論維度和密度如何，我們的高品質方法都是透過兩個關鍵構建塊的獨特分層整合來實現的。在更高層次上，我們應用標記的網格重新排列演算法（GRA），能夠透過行/列洗牌對網格進行有效的重新配置。在較低級別，我們設計了新穎的方法來有效地模擬 GRA 返回的行/列洗牌。我們基於 GRA 的演算法的實現在廣泛的數值評估中非常有效，與其他 SOTA 方法相比，表現出色的可擴展性。例如，在 3D 設定中，基於 GRA 的演算法可以輕鬆擴展到具有超過 370,000 個頂點和超過 120,000 個代理的網格，並始終實現接近 1.5 的保守完工時間最優性，正如我們的理論分析所預測的那樣。

一、簡介

我們在具有潛在規則分佈障礙的二維和三維網格上檢查多智能體尋路（MAPF（Stern 等人，2019））（見圖 1）。MAPF 的主要目標是找到用於將許多代理程式從起始設定路由到目標配置的無衝突路徑。在實踐中，解決方案的最優性至關重要，但最佳化求解 MAPF 是 NP 困難的（Surynek，2010；Yu & LaValle，2013b），即使在平面設定（Yu，2015）和無障礙網格上（Demaine 等人，2019）。MAPF 演算法適用於各種實際場景，包括編隊重新配置（Poduri & Sukhatme，2004）、物體運輸（Rus、Donald 和 Jennings，1995）、群體機器人（Preiss 等人，2017 年；Hönig 等人，2018），僅列出一些。即使受限於類似網格的設置，MAPF 演算法仍可找到許多大規模應用，包括用於一般訂單履行的倉庫自動化（Wurman、D. Andrea 和 Mountz，2008）、雜貨訂單履行（Mason，2019 年）和包裹排序（Wan 等，2018）。

受訂單履行和包裹分揀等應用程式的推動，我們專注於具有極高代理密度的網格狀設置，即具有或更多圖形頂點

郭&於




圖 1：(a) 真實世界的包裹分揀系統（京東）在大型網格狀環境中使用許多代理，並帶有用於投遞包裹的孔；(b) 我們的方法可以在多項式時間內求解的類似 MAPF 實例的快照，並具有可證明的最優性保證。在實踐中，我們的演算法可擴展到尺寸超過 450×300 的 2D 地圖，支援超過 45K 個代理並實現優於 1.5 的最優性（參見圖 14）。它們在 3D 設定中進一步縮放。

被代理佔領。儘管最近的研究（Yu, 2018; Demaine 等人, 2019）表明此類問題可以在多項式時間內解決，產生常數因子最優解，但常數因子太高 ($\gg 1$)，不實用。在這項研究中，我們拆除了這個 MAPF 規劃障礙，在多項式時間內以高機率漸近地實現 $(1 + \delta)$ -makespan 最優性，其中 $\delta \in (0, 0.5]$ 對於 2D 網格和 $\delta \in (0,$

$\frac{2}{3}]$ 對於 3D 網格。

本研究的主要理論和演算法貢獻概述如下，並總結在表 1 中。& Yu, 2023) 採用許多經典演算法技術，並結合仔細分析，我們確定在低多項式時間內：

對於 2D $m_1 \times m_2$ 網格上的 $m_1 m_2$ 智能體， $m_1 \geq m_2$ ，即在最大智能體密度下，GRM（MAPF 網格重排）在 $4m_1 + 8m_2$ 的完工時間內計算任意 MAPF 實例的解；對於 3D $m_1 \times m_2 \times m_3$ 網格上的 $m_1 m_2 m_3$ 智能體， $m_1 \geq m_2 \geq m_3$ ，GRM 在 $4m_1 + 8m_2 + 8m_3$ 的完工時間內計算解決方案；

為了 $\frac{1}{13}$ 具有均勻隨機分佈的開始/目標配置的代理密度，GRH（高速公路網格重排）在 2D 網格上計算完成時間為 $m_1 + 2m_2 + o(m_1)$ 的解決方案，在 3D 網格上計算完成時間為 $m_1 + 2m_2 + 2m_3 + o(m_1)$ 的解。機率很高。相反，對於 2D 網格，此類實例的最小完工時間為 $m_1 + m_2 - o(m_1)$ ；對於 3D 網格，此類實例的最小完工時間為 $m_1 + m_2 + m_3 - o(m_1)$ 。這意味著，如

1. (Szegedy & Yu, 2023) 指出他們的魔術方塊表演算法可以用來解 MAPF；我們並不認為這是對我們工作的貢獻。相反，我們的貢獻是透過細緻的演算法設計和仔細的分析相結合來顯著降低常數因子。

此外，我們也發展了許多有效且有原則的啟發法，可以協同工作使用基於 GRA 的演算法進一步顯著縮短計算完工時間利潤。這些啟發式方法包括 (1) 最佳化匹配方案，基於線性瓶頸分配的網格重排演算法的應用 (LBA)，(2) 一種壓縮解路徑的多項式時間路徑細化方法以提高他們的素質。透過廣泛的評估表明，我們的方法是高度可擴展，能夠處理數以萬計的密集實例代理。同時，所實現的最優性符合/超過我們的理論預測。隨著可擴展性的大大增強，我們的方法揭示了一個有希望的方向開發實用的、可證明最優的多代理路由演算法，運行在低多項式時間。

演算法	GRM 2x3 GRM 4x2		GRLM 1	生物觀察時間表
適用密度	≤ 1	$\leq 1 \leq$	$\leq \frac{1}{2}$	$\frac{1}{3}$
完工上限 $7(2m^2 + m_1) 4(2m^2 + m_1) 4m^2 + 3m_1 4m^2 + 3m_1$				
漸近完工時間 $7(2m^2 + m_1) 4(2m^2 + m_1) 2m^2 + m_1 + o(m_1)$				
漸近最適性 $7(1 + 4(1 + 1) + m_1)m^2$	$\frac{\text{平方厘米}}{\text{米}^2 + \text{米}^2}$	$\frac{\text{平方厘米}}{\text{米}^2 + \text{米}^2}$	$1 + \frac{\text{平方厘米}}{m_1 m^2}$	$\frac{\text{平方厘米}}{\text{米}^2 + \text{米}^2}$

在尺寸為 $m1 \times m2$ 的網格上。GRH、GRM 和 GRLM 均進一步派生
來自 GRA2D，每個變體都以獨特的低級洗牌運動為特徵。
專門針對 GRM，低階洗牌運動是為促進
全密度機器人運動

第445章

開發顯著提高所有基於 GRA 的演算法生成的計劃的最優性；(3) 為論文中的所有理論發展提供了完整且充分完善的證明；(4) 評估部分進行了全面修改，以反映最新的理論和演算法發展。

相關工作。關於多智能體路徑和運動規劃的文獻 (Hopcroft、Schwartz 和 Sharir, 1984; Erdmann 和 Lozano-Perez, 1987) 非常廣泛；在這裡，我們主要關注圖論（即狀態空間是離散的）研究 (Yu & LaValle, 2016; Stern et al., 2019)。因此，在本文中，MAPF 明確指的是基於圖的多智能體路徑規劃。儘管可行性問題早已得到了正面的回答 (Kornhauser、Miller 和 Spirakis, 1984)，但對於尋找最優解卻不能這麼說，因為計算時間或距離最優解在許多設定中都是 NP 困難的，包括一般情況下圖 (Goldreich, 2011; Surynek, 2010; Yu & LaValle, 2013b)、平面圖 (Yu, 2015; Banfi, Basilico, & Amigoni, 2017) 和規則網格 (Demaine et al., 2019) 類似於這項工作中所研究的環境。

儘管如此，鑑於其高實用性，特別是在電子商務應用中 (Wurman et al., 2008; Mason, 2019; Wan et al., 2018)，預計將顯著增長 (Dekhtyn, et al., 2019; LogisticsIQ, 2020)，已經提出了許多演算法解決方案來最佳化求解 MAPF。其中，基於組合搜尋的求解器 (Lam 等人, 2019) 已被證明相當有效。MAPF 求解器可分為最優或次優。基於約簡的最優求解器透過將 MAPF 問題約簡為另一個問題來解決問題，例如 SAT (Surynek, 2012)、答案集規劃 (Erdem, et al., 2013)、整數線性規劃 (ILP) (Yu & LaValle, 2016)。基於搜尋的最優 MAPF 求解器包括 EPEA* (Goldenberg, et al., 2014)、ICTS (Sharon, et al., 2013)、CBS (Sharon, et al., 2015)、M* (Wagner & Choset, 2015)，以及許多其他人。

由於最優 MAPF 固有的棘手性，最優求解器通常表現出有限的可擴展性，導致人們對次優求解器產生極大興趣。無界求解器，如推入交換 (Luna & Bekris, 2011)、推入旋轉 (De Wilde, Ter Mors, & Witteveen, 2014)、視窗分層協作 A* (Silver, 2005)、BIBOX (Surynek, 2009)，所有可行的解決方案都很快返回，但以解決方案品質為代價。平衡運行時間和最適性是 MAPF 研究中最具吸引力的主題之一。一些演算法在不犧牲最優性的情況下強調可擴展性，例如 ECBS (Barer, et al., 2014)、DDM (Han & Yu, 2020)、PIBT (Okumura, et al., 2019)、PBS (Ma, et al., 2019)。還有一些基於學習的求解器 (Damani, et al., 2021; Sartoretti, et al., 2019; Li, et al., 2021) 可以在稀疏環境中很好地擴展。也提出了有效的正交啟發法 (Guo、Han 和 Yu, 2021)。最近，人們提出了 $O(1)$ 近似或常數因子時間最優演算法，例如 (Yu, 2018; Demaine 等人, 2019; Han、Rodriguez 和 Yu, 2018)，用於處理高密度實例。然而，這些演算法只能以非常大的常數因子為代價來實現低多項式時間保證，這使得它們在理論上很有趣但不切實際。

相反，我們的方法以高機率在低多項式時間內運行，並具有可證明的 $1.1x$ 漸近最優性。據我們所知，本文提出了第一個同時保證多項式運行時間和 $1.1x$ 解最優性的 MAPF 演算法，適用於任何 ≥ 2 的維度。

組織。本文的其餘部分組織如下。在秒。2. 從 2D 網格開始，我們提供了基於圖的 MAPF 的形式化定義，並引入了 Grid

重排問題和解決該問題的相關基線演算法（GRA）。GRM 是GRA 在最大藥劑密度下針對 MAPF 的基本改編，可確保完工時間上限為 $4m_1 + 8m_2$ ，在第 2 節中進行了描述。3.也建立了隨機 MAPF 實例的伴隨下界 $m_1 + m_2 - o(m_1)$ 。在秒。在圖 4 中，我們引入了代理密度，其完工時間上限為 $m_1 + 2m_2 + o(m_1)$ 。然後討論支持GRH 的障礙。我們繼續展示如何透過類似的最優性保證來支援代理密度。在秒。5.我們將演算法推廣到 3+D網格。在秒。在圖 6 中，我們引入了多種最佳化提升啟發式方法，以顯著提高基於網格重新排列的求解器的所有變體的解決方案品質。我們在第二節中徹底評估了我們方法的性能。7 並以 Sec 結束。8.

2. 預賽

2.1 圖上的多智能體路徑查找（MAPF）

考慮一個無向圖 $G(V, E)$ 和 n 個具有起始配置 $S = \{s_1, \dots, s_n\} \subseteq V$ 和目標配置 $G = \{g_1, \dots, g_n\} \subseteq V$ 。代理 i 的路徑是映射 $\pi_i: N \rightarrow V$ ，其中 N 是非負整數集合。可行的 π_i 必須是連接 s_i 和 g_i 的頂點序列：1) $\pi_i(0) = s_i$ ；2) $\exists T_i \in N, \forall t \geq T_i, \pi_i(t) = g_i$ ；3) $\forall t > 0, \pi_i(t) = \pi_i(t - 1)$ 或 $(\pi_i(t), \pi_i(t - 1)) \in E$ 。... , P_n 是可行的，當且僅當每個 P_i 都是可行的，並且對於所有 $t \geq 0$ 且 $1 \leq i < j \leq n$ ， $\pi_i(t) \neq \pi_j(t)$ ，不會發生：1)

$\pi_i(t) = \pi_j(t)$ ；2) $\pi_i(t) = \pi_j(t + 1) \wedge \pi_j(t) = \pi_i(t + 1)$ 。

我們使用 G 在 2D 中為 4 個連接的網格，在 3D 中為 6 個連接的網格，主要目的是最小化完工時間，即 $\max_i \{|\pi_i|\}$ （稍後還簡要檢查了成本總和目標）。除非另有說明，否則假設 G 是 $m_1 \times m_2$ 網格，在 2D 中為 $m_1 \geq m_2$ ，在 3D 中為 $m_1 \times m_2 \times m_3$ 網格，其中 $m_1 \geq m_2 \geq m_3$ 。需要說明的是，本文中的「隨機性」始終指均勻隨機性。我們研究的 MAPF 版本有時被稱為一次性 MAPF（Stern 等人，2019）。我們提到我們的結果也可以轉化為終身環境的保證（Stern 等人，2019），這在第 2 節中進行了簡要討論。8.

2.2 網格重排問題（GRP）

網格重排問題（GRP）（首次在（Szegedy & Yu，2023）中提出，稱為魔術方塊表問題）形式化了在格子上執行全域協調物件重配置操作的任務，並具有許多有趣的應用。這個問題有很多變體；我們從二維形式開始，稍後推廣到更高維度。

問題 1（二維網格重排問題 (GRP2D)（Szegedy & Yu，2023））。

設 M 為 m_1 (行) $\times$ m_2 (列)表， $m_1 \geq m_2$ ，包含 $m_1 m_2$ 個項目，每個表格單元格中有一個。這些物品有 m_2 種顏色，每種顏色的多重數為 m_1 。在混洗作業中， M 的單列或單行中的項目可以任意排列。給定項目的任意配置 X_i ，找到一系列洗牌序列，將 M 從 X_i 帶到第 i 行（ $1 \leq i \leq m_1$ ）僅包含顏色 i 的項目的配置。

問題也可以是有標籤的，即每一項在 1, 中都有一個唯一的標籤。... , 平方米。

一個關鍵結果（Szegedy & Yu，2023），我們在這裡表示為（標記的）二維網格重排演算法（GRA2D），表明可以使用 m_2 列洗牌和 m_1 行洗牌來解決彩色GRP2D，這意味著低多項式時間計算

時間。然後進行額外的 m_1 行洗牌，然後求解標記的 GRP2D。我們說明 GRA2D 如何在 $m_1 \times m_2$ 表上運作，其中 $m_1 = 4$ 且 $m_2 = 3$ (圖 2)；我們建議讀者參閱 (Szegedy & Yu, 2023) 以了解詳細資訊。主要支持理論結果在定理 2.2 中給出，它依賴定理 2.1。

定理 2.1 (具有平行邊的 Hall 匹配定理 (Hall, 2009; Szegedy & Yu, 2023))。設 B 是 $n + n$ 個節點上的 d -正規 ($d > 0$) 二部圖，可能有平行邊。那麼 B 就有了完美的搭配。

定理 2.2 (網絡重排定理 (Szegedy & Yu, 2023))。 $m_1 \times m_2$ 表上的任意網絡重新排列問題可以使用 $m_1 + m_2$ 洗牌來解決。標記的網絡重新排列問題可以使用 $2m_1 + m_2$ 洗牌來解決。

GRA2D 分兩階段運作。首先，基於初始表建構二分圖 $B(T, R)$ ，其中二分集 T 是項目的顏色/類型，集合 R 是表格的行 (見圖 2(b))。對於 r 行中顏色 t 的每個項目，在 $t \in T$ 和 $r \in R$ 之間向 B 加上一邊。根據定理 2.1 所保證的 $B(T, R)$ (正規二分圖)，可以計算出 m_2 個完美匹配。每個包含 m_1 條邊的匹配決定了第一階段之後表列的外觀。例如，第一組配對 (圖 2(b) 中的實線) 表示第一列應排序為黃色、青色、紅色和綠色，如圖 2(c) 所示。處理完所有符合後，我們得到一個中間表，如圖 2(c)。注意圖 2(a) 的每一行都可以被打亂以產生圖 2(c) 的對應行；GRA2D 的一項重要創新之處。在 m_1 行洗牌的第一階段之後，中間表 (圖 2(c)) 可以用 m_2 列洗牌重新排列，以解決彩色 GRP2D (圖 2(d))。另一個 m_1 行洗牌然後求解標記的 GRP2D (圖 2(e))。也可以使用 m_2 列洗牌、隨後 m_1 行洗牌、隨後另一個 m_2 列洗牌來執行重新排列。




圖 2 :應用 11 次洗牌的圖示。(a) 最初的 4×3 表格，隨機排列 12 個帶有顏色和標籤的項目。標籤與顏色一致。(b) 建構的二分圖。它包含 3 個完美匹配，確定 (c) 中的 3 列；在這個階段只有顏色很重要。(c) 根據配對結果，對 (a) 套用 4 行洗牌，得到一個中間表，其中每列一種顏色只出現一次。(d) 對 (c) 套用 3 列洗牌，求解彩色 GRP2D。(e) 4 個額外的行洗牌對標記的項目進行完全排序。

GRA2D 的運行時間為 $O(m_1 m_2 \log m_1)$ (請注意, 這與 $n = m_1 m_2$ 項目總數) 預期時間或 $O(m_2 \log m_2)$ 確定性時間。

3. 利用 GRA2D 求解最大密度下的 MAPF

GRA2D 內建的全局協調能力自然適用於求解 makespan 最優 MAPF。由於 GRA2D 只需要三輪洗牌, 並且每輪涉及並行行洗牌或併行列洗牌, 如果每輪洗牌都可以通過與行/列大小成正比的 makespan 來實現, 那麼 makespan 上限為 $O(m_1 + m_2)$ 可以保證。事實上, 即使當 G 的所有頂點都被智能體佔據時, 透過遞歸地應用標記線洗牌演算法 (Yu, 2018), 這也是可以實現的, 該演算法可以使用 $O(m)$ 的完工時間任意重新排列嵌入網絡中的 m 個智能體的線。

引理 3.1 (基本模擬標記線洗牌 (Yu, 2018))。對於嵌入在二維網絡中的長度為 m 的直線路徑上的 m 個標記代理, 它們可以以 $O(m)$ 的步驟任意排序。此外, 可以在網絡內的平行路徑上執行多個此類重新配置。

關鍵操作基於本地化的三步驟對交換例程, 如圖 3 所示。有關 line shuffle 例程的更多詳細信息, 請參閱 (Yu, 2018)。




圖 3: 在 2×3 網絡上, 交換兩個代理可以透過三個循環輪換分三步驟執行。

然而, 基本的模擬標記行洗牌演算法具有較大的常數因子。每次洗牌需要 3 步; 對 2×3 進行任意洗牌通常需要 20 多個步驟。當我們協調多條線的洗牌時, 常數因子進一步複合。

借用平行奇偶排序的想法 (Bitton et al., 1984), 我們可以大幅減少引理 3.1 中的常數因子。我們將分幾個步驟來完成此操作。首先, 我們需要以下引理。網絡上的任意水平交換是指任意重新配置或網絡行。

引理 3.2。對 3×2 、 4×2 、 2×3 、 3×3 、 2×4 和 3×4 進行任意水平交換的任意組合最多需要 7、6、6、7、6 和 8 步網絡, 分別。

證明。使用整數線性規劃 (Yu & LaValle, 2016), 我們詳盡地計算了 3×2 ($8 = 2^3$ 種可能情況)、 4×2 網絡 (2 種可能情況)、 2×3 網絡 (6 種可能的情況)、 2×4 網絡 (242 種可能的情況) 和 3×4 網絡 (243 種可能的情況), 證實了可能的情況) 3×3 網絡 (6^3)

索賠。

□




圖 4 :在 3×2 網格上進行完全水平「交換」的範例，需要七個步驟，所有三對都被交換。

舉個例子，需要七個步驟來水平「交換」一個網路上的所有三對代理。
 3×2 網格，如圖4所示。

引理 3.3（快速行洗牌）。嵌入在 2D 網格中，長度為 m 的直線路徑上的 m 個智能體可以以 $7m$ 步長任意排序。此外，多個這樣的重新配置可以在網格內並行執行。

證明。在長度為 m 的直線路徑上排列 m 個智能體可以透過在 $m-1$ 輪中使用平行奇偶排序（Bitton 等人，1984）來實現，這僅需要能夠模擬潛在的成對「交換」交錯奇數階段（交換（對於某些 k ，交換位於路徑上位置 $2k+1$ 和 $2k+2$ 的代理）甚至階段（交換位於路徑上對於某些 k 的位置 $2k+2$ 和 $2k+3$ 的代理）。這裡， m 是奇數還是偶數並不重要。為了模擬這些交換，我們可以在兩個階段中以兩種方式將嵌入路徑的網格劃分為 3×2 網格，如圖 5 所示。




圖 5 :以兩種方式將網格劃分為不相交的 3×2 網格，以模擬奇偶排序。突出顯示的代理程式對可以根據需要在每個 3×2 網格內獨立「交換」。

完美的分區要求垂直於直線路徑的網格的第二維是3的倍數。根據引理 3.2，每個奇偶排序階段最多可以使用 $7m$ 步來模擬。直接支援並行路徑上的洗牌。

□

在介紹了 $7m$ 的階梯線洗牌之後，我們進一步展示瞭如何使用類似的想法將其降至 $4m$ 。不同之處在於，更新的平行奇偶排序將與大小不同於 2×3 和 2×4 的不同子網格一起使用。

更新後的平行奇偶排序對四個區塊（圖 6）而不是兩個區塊（圖 5）進行操作，這將並行排序操作的數量從 $m - 1$ 減少到大約 $m/2$ 。這裡，如果 m 不為偶數，則分區將在末尾留下 1 或 3。例如，如果 $m=11$ ，則在兩個並行排序階段中可以將其劃分為 4,4,3 和 2,4,4,1。




圖 6：透過增加交換，我們可以讓平行奇偶排序的速度提高兩倍，塊大小從兩個到四個。

透過更新的平行奇偶排序，我們必須能夠對四個區塊進行交換。我們透過將 $m_1 \times m_2$ 網格劃分為 2×4 來實現此目的，其中可能具有大小為 2×3 、 3×4 和 3×3 的剩餘子網格。使用相同的推理，我們有

引理 3.4（更快的行洗牌）。嵌入 2D 網格中，長度為 m 的直線路徑上的 m 個智能體可以以大約 $4m$ 的步長任意排序。此外，多個這樣的重新配置可以在網格內並行執行。

證明草圖。更新後的平行奇偶排序總共需要 $m/2$ 步驟。由於每個步驟都在 2×4 、 2×3 、 3×4 或 3×3 網格上運行，最多需要 8 步，因此總完工時間約為 $4m$ 。

□

結合 GRA2D 和快速線洗牌（引理 3.4）產生多項式時間 MAPF

適用於完工時間為 $4m_1 + 8m_2$ 的完全佔用網格的演算法。

定理 3.1（最大代理密度下網格上的 MAPF，上限）。 $m_1 \times m_2$ 網格上的 MAPF， $m_1 \geq m_2 \geq 3$ ，每個網格頂點都由一個代理佔據，可以在 $4m_1 + 8m_2$ 的完工時間內以多項式時間求解。

證明草圖。透過結合 GRA2D 和行洗牌演算法，可以透過兩個行洗牌階段和一個列洗牌階段有效地解決這個問題。在 row-shuffle 階段，所有行可以以 $4m_2$ 的步驟進行洗牌，同樣，在列-shuffle 階段，所有的列可以以 $4m_1$ 的步驟進行洗牌。總結這些步驟，整個問題可以透過 $4m_1 + 8m_2$ 步驟來解決。主要計算負擔在於計算完美匹配，該任務可在 $O(m_1 m_2 \log m_1)$ 預期時間或 $O(m_2^2 m_1)$ 確定時間內完成。

□

很明顯，透過進一步利用這個想法，在全密度設定下可能會獲得更小的完工時間，但擴展引理 3.2 所需的計算將變得更具挑戰性。例如，計算 3×4 網格的所有 243 個案例大約需要兩天。

我們將過程產生的演算法稱為 GRM（對於 2D），其中「M」表示最大密度，無論使用的子網格如何。Alg 中給出了簡單的偽代碼。1. GRM 主例程中的註解指示對應的 GRA2D 階段。對於具有行列座標(x, y)的 $m_1 \times m_2$ 網格上的 MAPF，如果 $g_i.y = j$ ，我們稱代理 i 屬於顏色 $1 \leq j \leq m_1$ 。第一階段的函數 `Prepare()` 透過完美匹配找到每個智能體的中間狀態 $\{\tau_i\}$ ，並透過（模擬的）列洗牌將它們路由到中間狀態。如果智能體密度小於要求，我們可以用「虛擬」智能體填滿表格（Han et al., 2018 ; Yu, 2018）。對於每個代理 i ，我們有 $\tau_i.y = s_i.y$ 。第二階段的函數 `ColumnFitting()` 透過行洗牌將代理程式路由到第二個中間狀態 $\{\mu_i\}$ ，其中 $\mu_i.x = \tau_i.x$ 且 $\mu_i.y = g_i.y$ 。在最後階段，函數 `RowFitting()` 使用額外的列洗牌將代理路由到最終目標位置。

演算法1 :基於標記網格重排的二維MAPF演算法 (GRA2D)

輸入 :起始頂點和目標頂點 $S = \{s_i\}$ 且 $G = \{g_i\}$

1 函數 `RTA2D(S, G)` :
2 準備 ($S \setminus G$)
3 柱配件($S \setminus G$)
4 行擬合(S, G)

5 函數 `Prepare(S, G)`: $A \leftarrow [1, \dots, m_1 m_2]$ for $(t, r) \in [1, \dots, m_1] \times [1, \dots, m_1]$ do
6 if $\exists i \in A$ where $s_i.x = r \wedge g_i.y = t$ 然後將邊 (t, r) 加到 $B(T, R)$ 從 A 移除 i
7 計算 $B(T, R)$ 的匹配 $M_1, \dots, M_{m_2}$
8 $A \leftarrow [1, \dots, m_1 m_2]$ foreach M_r and $(t, r) \in M_r$ do if $\exists i \in A$ where $s_i.x = r \wedge g_i.y = t$ then $\tau_i \leftarrow (r, s_i.y)$ 並從 A 標記代理 i 中刪除 i 前往 τ_i
9 並執行模擬列洗牌
10
11 函數 `ColumnFitting(S, G)`: foreach $i \in [1, \dots, m_1 m_2]$ do $\mu_i \leftarrow (\tau_i.x, g_i.y)$ 並標記代理 i 到 μ_i 並執行模擬行洗牌
12
13 函數 `RowFitting(S, G)`: foreach $i \in [1, \dots, m_1 m_2]$ do 標記代理 i 去 g_i 並執行模擬列洗牌

我們現在建立 GRM 在 2D 網格上的最優性保證，假設 MAPF 實例是隨機產生的。為此，需要一個精確的下限。

命題 3.1 (二維網絡上 MAPF 的精確完工時間下限) 。具有 $\Theta(m_1m_2)$ 代理人的 $m_1 \times m_2$ 網絡上的隨機 MAPF 實例的最小完工時間是 $m_1 + m_2 - o(m_1)$, 其中任意高機率為 $m_1 \rightarrow \infty$ 。

證明 。不失一般性 , 令 $\Theta(m_1m_2)$ 中的常數為某個 $c \in (0, 1]$, 即存在 cm_1m_2 主體 。我們檢查 $m_1 \times m_2$ 網絡 G 的左上角和右下角 。特別是 , 令 G_{tl} (resp., G_{br}) 為 G 的左上 (resp., 右下) $\frac{1}{4}m_1 \times \frac{1}{4}m_2$ 子網絡 , 對於某個正常數 $\alpha \ll 1$ 。對於 $u \in V(G_{tl})$ 和 $v \in V(G_{br})$, 假設每個網絡邊都有單位距離 , 則 u 和 v 之間的曼哈頓距離至少為 $(1 - 2\alpha)(m_1 + m_2)$ 現在 , 某些 $u \in V(G_{tl})$ 和 $v \in V(G_{br})$ 的機率 。開始

對於單一智能體 , 起始點和目標分別為 α 至少一個智能體的起始 $\frac{1}{4}$ 點和目標分別落入 G_{tl} 和 G_{br} 中 , 分別為 $p = 1 - (1 - \alpha)^4$ 公分 $\frac{1}{4}$ 。
因為 $(1 - x)^y < e^{-xy}$ 對於 $0 < x < 1$ 且 $y > 0$, $p > 1 - e^{-\alpha cm_1m_2}$ 平方公尺 。因此 , 對於任意小的 α , 我們可以選擇 m_1 使得 p 任意接近 1 。
我們可以令 $\alpha = \frac{1}{8\sqrt{m_1}}$,
是 $(1 - 2\alpha)(m_1 + m_2) = m_1 + m_2 - 2m - c\sqrt{m_1m_2} p > 1 - \frac{1}{8}(m_1 + m_2) = m_1 + m_2 - o(m_1)$ 機率 $\square$

比較定理 3.1 所建立的上限和命題 3.1 所建立的下限 , 立即得出

定理 3.2 (GRM 的最適性保證) 。對於具有 $\Omega(m_1m_2)$ 代理人的 $m_1 \times m_2$ 網絡上的隨機 MAPF 實例 , 當 $m_1 \rightarrow \infty$ 時 , GRM 以多項式時間解計算 , 即 $4(1 + \frac{\text{平方米}}{\text{米}_1 + \text{米}_2})$ -makespan 最優 , 機率很高 。

證明草圖 。由命題 5.1 和定理 3.1 可知 , 漸近最適性比為 $4(1 + \frac{\text{平方米}}{\text{米}_1 + \text{米}_2})$ 。

GRM 始終以多項式時間運行 , 與 GRA2D 的運行時間相同 ; 高機率保證僅涉及解決方案的最優性 。本文提出的其他高機率演算法也是如此 。我們也注意到 , 高機率的保證意味著預期的保證 。

4. 代理密度高達三分之一和二分之近的近乎最優求解 MAPF

儘管 GRM 在多項式時間內運行並提供期望的恆定因子完工時間最優性 , 但由於極端密度 , 恆定因子為 $4 + \frac{\text{平方米}}{\text{米}_1 + \text{米}_2}$ 。在實踐中 , 一個代理人 (即 $n = \frac{m_1m_2}{3}$) 已經非常高了 。事實證明 , 當 $n = \frac{m_1m_2}{3}$ 時 , 常數因子可以降至接近 1 。
對於某個常數 $c > 0$ 且 $\frac{m_1m_2}{3} \leq n \leq \frac{m_1m_2}{2}$ 的周圍密度

4.1 高達三分之一的密度 : 利用高速公路啟發式進行洗牌

為了 $\frac{1}{3}$ 密度 , 我們在本小節使用隨機 MAPF 實例 ; 達到密度的任意實例將在後面的小節中討論 。我們暫時假設 $m_1 \geq m_2$ 。

2. 這是因為 $\log(1 - x) < -x$ 對於 $0 < x < 1$; 兩邊同時乘以正 y 並取冪以 e 為底 , 則得不等式 。

m_2 是三的倍數；我們將 G 劃分為 3×3 個單元（參見圖 1(b) 和圖 7）。

我們使用圖 7，其中圖 7(a) 是隨機開始配置，圖 7(f) 是隨機目標配置，作為範例來說明 GRH - 高速公路網絡重新排列，目標代理密度高達 3。GRH 有兩個階段：無標籤重新配置和使用網絡重新排列和高速公路啟發式的 MAPF 解析。




圖 7：應用 GRH 求解 MAPF 實例的範例。(a) 啟動配置；(b) 由(a)所得的起始平衡配置；(c) 網絡重排準備階段所獲得的中間配置；(d) 由(c)所得的中間構型；(e) 柱擬合階段所獲得的中間構型；(f) 對標記的項目套用額外的列洗牌；(g) 由目標配置所得到的目標平衡配置；(h) 目標配置。

在未標記的重新配置中，代理被視為無法區分。任意起始和目標配置（在代理密度下）將轉換為中間配置，其中每個 3×3 單元包含不超過 3 個代理程式。我們稱這種配置為平衡的。

隨機 MAPF 實例離平衡不遠了，機率很高。為了確定這個結果（命題 4.1），我們需要以下內容。

定理 4.1（最小最大網絡匹配（Leighton & Shor, 1989））。考慮一個 $m \times m$ 的正方形，其中包含服從均勻分佈的 m_2 個點。設 ℓ 為最小長度，使得 m_2 個點與正方形中的網絡點存在完美匹配，且每對匹配點之間的距離至多為 ℓ 。那麼 $\ell = O(\log \frac{m_2}{m})$ 的機率很高。

$\frac{3}{4}m$

定理 4.1 也適用於長邊為 m 的矩形（定理 3（Leighton & Shor, 1989））。

命題 4.1 在 $m_1 \times m_2$ 網絡上，很有可能隨機配置

$n = \frac{\text{平方米}}{3}$ 代理與平衡配置的距離為 $o(m_1)$ 。

證明。我們使用極小極大網絡匹配定理（定理 4.1）證明了 $m_1 = m_2 = 3m$ 的情況；然後，使用適用於矩形的定理 4.1 的廣義版本（Leighton & Shor, 1989）的定理 3，適用於正方形區域內的任意單連通區域，可以看出推廣到 $m_1 \geq m_2$ 是成立的。

現在讓 $m_1 = m_2 = 3m$ 。我們可以將 $3m \times 3m$ 網絡上的 m_2 個智能體的隨機配置視為將 m_2 個連續點隨機放置在一個 $m \times m$ 的正方形中，並進行縮放（每個維度為 3）和舍入。由定理 4.1 可知， $m \times m$ 方格內的 m_2 個連續點的隨機配置可以移動到 $m \times m$ 方格內 m_2 個不相交單位方格中心的 m_2 個網絡點，其中每個點移動距離 $4m$ ，機率很高。將其轉換回 $3m \times 3m$ 網絡， m_2

網絡上隨機分佈的智能體³

可以移動不超過 $O(\log)$ ，以便每個 3×3 單元恰好包含一個智能體，並且任何智能體移動的最大距離不超過 $O(\log)$ 高機率。應用此參數 3 次得出 $m_1 \times m_1$ 網絡上代理的隨機配置可以移動，以便每個 3×3 單元恰好包含三個 $4 \frac{3}{4}m$ ，與 m_1 步驟，機率很高。

$\frac{\text{平方米}}{3}$

代理，並且沒有代理需要移動超過 $O(\log)$ 因為代理是不可區分的，所以覆蓋三組重新配置路徑不會導致任何代理移動距離的增加。

□

在範例中，未標記的重新配置對應於圖 7(a) → 圖 7(a) → 圖 7(a) → 圖 7(b)。圖 7(b) 和圖 7(f) → 圖 7(f) → 圖 7(b) 和圖 7(f) → 圖 7(b) 和圖 7(f) → 圖 7(e)（MAPF 解決方案是時間可逆的）。我們模擬了 $m_1 = m_2 = 300$ （即在 300×300 網絡上的無標籤重新配置過程。對於智能體密度，100 個隨機實例的實際平均步數小於 5。單元格居中平衡或簡單居中。完成第一階段需要解決兩個未標記的問題（Yu & LaValle, 2012; Ma & Koenig, 2016），這可以在多項式時間內完成。

在第二階段，GRA 與高速公路啟發式一起應用，使我們從圖 7(b) 到圖 7(e)，在垂直居中配置和水平居中配置之間進行轉換。為此，應用 GRA（例如，圖 7(b) 和 (e)）以獲得兩個中間配置（例如，圖 7(c) 和 (d)）。要在這些配置之間切換，例如，圖 7(b) → 圖 7(b) → 圖 7(b) → 圖 7(b) → 圖 7(b) 如圖 7(c) 所示，我們應用啟發式方法，根據目標方向將需要從 3×3 單元中移出的代理人移至圖 7(b) 中間列的兩側。如果我們始終如一地這樣做，那麼在將智能體移出中間列後，我們可以將所有智能體移動到所需的目標 3×3 單元格，而無需停止或碰撞。一旦所有智能體都位於正確的 3×3 單元中，我們最多可以透過 3 個步驟將平衡配置轉換為居中配置，這對於執行下一個模擬行/列洗牌是必要的。加起來，我們可以使用不超過 $m + 5$ 個步驟來模擬洗牌操作，其中 $m = m_1$ 或 m_2 。有效模擬的洗牌導致 MAPF 演算法的完工時間較短。很明顯，所有操作都需要多項式時間；本小節末尾給出了精確的運行時間。

定理 4.2（隨機 MAPF 的完工上限，≤ 密度）。對於 $m_1 \times m_2$ 網絡上的隨機 MAPF 實例₃，其中 $m_1 \geq m_2$ 是三的倍數，且 $n \leq$ 米¹米²3

郭&於

對於智能體， $m_1 + 2m_2 + o(m_1)$ 的完工時間解可以在多項式時間內以很高的機率計算出來。

證明。根據命題 4.1，無標籤重配置以高機率需要距離 $o(m_1)$ 。這意味著可以獲得需要 $o(m_1)$ 完工時間的無標籤重新配置計劃（詳細證明請參見 (Yu, 2018) 中的定理 1）。對於第二階段，根據定理2.2，我們需要執行 m_1 個行寬為 m_2 的平行行洗牌，然後執行 m_2 個列寬為 m_1 的並行列洗牌，然後再執行另一個 m_1 個行寬為 m_2 的並行列洗牌。模擬這些洗牌需要 $m_1 + 2m_2 + O(1)$ 步驟。總而言之，所需的完工時間為 $m_1 + 2m_2 + o(m_1)$ ，機率非常高。

□

對比定理 4.2 和命題 3.1 得出

定理 4.3（隨機 MAPF 的完工時間最適性，≤密度）。對於 $m_1 \times m_2$ 網格上的隨機MAPF 實例，其中 $m_1 \geq m_2$ 是3的倍數，對於 $n = cm_1m_2$ 代理，在多項式時間內 $c \leq \frac{2}{9}$ ，機率很高。

當 $m_1 \rightarrow \infty$, $a(1 + \frac{\frac{\text{平方米}}{\text{米}_1 + \text{米}_2}}{13})$ 可以計算完工時間最優解

由於 $m_1 \geq m_2$ ，1+以高機率 $\frac{m_2}{m_1+m_2} \in (1, 1.5]$ 。換句話說，在多項式運行時間內，GRH 實現 $\delta \in (0, 0.5]$ 的 $(1 + \delta)$ 漸近完工時間最優性。

從目前的分析來看，如果 m_1 和/或 m_2 不是 3 的倍數，則顯然所有本小節的結果對於人員密度繼續成立。任意接近具有一定規律分佈的障礙物的圖案（圖1（b）），即

$\frac{1}{13} - \frac{(m_1 \bmod 3)(m_2 \bmod 3)}{\text{平方米}}$ ，這是

對於大的 m_1 和 m_2 。同樣清楚的是，對於網格也可以這樣說

推論 4.1（隨機 MAPF，藥劑密度）。對於 $m_1 \times m_2$ 網格上的隨機 MAPF實例，其中 $m_1 \geq m_2$ 是3的倍數，並且對於所有適用的 k_1 和 k_2 ，坐標 $(3k_1 + 2, 3k_2 + 2)$ 處存在障礙物，對於具有解的 $n = cm_1m_2$ 智能體可以在多項式時間內計算，且高機率具有 makespan $m_1 + 2m_2 + o(m_1)$ $c \leq \frac{2}{9}$ 。當 $m_1 \rightarrow \infty$ 時，解以很高的機率接近 $1 + \frac{\frac{\text{平方米}}{\text{米}_1 + \text{米}_2}}{13}$ 最優解。

證明。由於機器人和障礙物的總密度不超過 $1/3$ ，如果定理 4.1擴展到支持規則分佈的障礙物，則定理 4.3 適用，因為高速公路啟發式不會穿過障礙物。這是事實，因為每個障礙只能為代理的路徑添加恆定長度的路徑繞行。換句話說，定理 4.3 中的長度 ℓ 只會增加一個常數因子，並且將保持為 $\ell = O(\log \ell)$ 類似的論點對於命題 4.1 也成立。

$\frac{3}{4}m$ 。 □

我們現在給出GRM和GRH的運行時間。

命題 4.2（運行時間，GRH）。對於 $n \leq \frac{m_1m_2}{13}$ ，運行時間為 $m_1 \times m_2$ 網格上的代理，GRH $O(nm_2 \log m_1)$ 。

證明。GRH 的運行時間主要由匹配計算和求解未標記的 MAPF 決定。匹配部分在確定性時間內花費 $O(m_2 \log m_1)$ 或在預期時間內花費 $O(m_1m_2 \log m_1)$ (Goel, Kapralov, & Khanna, 2013)。未貼標籤的 MAPF 可能會被解決

使用最大流量演算法 (Ford & Fulkerson, 1956), 時間為 $O(nm^2T) = O(nm^2 \log m)$, 其中 $T = O(m^2)$ 是時間擴展圖的擴展時間範圍, 允許需要完成的路線規劃。□

4.2 二分之一代理密度: 線性合併洗牌

使用更複雜的洗牌例程, 大部分保證 $\frac{1}{2}$ 可以支持藥劑密度, 同時保留 $\frac{1}{3}$ 密度設定; 不再支持障礙物。

為了最好的處理 $\frac{1}{2}$ 代理密度, 我們採用稱為線性合併的新洗牌例程, 基於合併排序, 並將結果演算法表示為具有線性合併的網格重排或 GRLM。基本想法很簡單: 對於 $2 \times m$ 網格上的 m 個代理, 我們迭代首先在 2×2 網格上對代理進行排序, 然後在 2×4 網格上排序, 依此類推, 就像合併排序一樣。圖 8 顯示了 2×8 網格上的製程示意圖。

演算法 2: 線合併演算法

輸入: 一個數組 arr , 表示標記為從 1 到 n 的頂點, 其中包含當前和 n 個代理的中間位置。

1 函數 $LineMerge(arr)$:

```

2   如果  $arr$  的長度 > 1 那麼
3        $mid \leftarrow arr$  的長度  $\div 2$ 
4        $left \leftarrow arr[0 \dots mid - 1]$ 
5        $right \leftarrow arr[mid \dots arr$  的長度  $- 1]$ 
6       行合併 ( $left$ )
7       線合併 ( $right$ )
8       合併 ( $arr$ )

```

9 函數合併 (arr):

```

10    對位於  $arr$  中頂點的智能體進行排序以獲得中間狀態
11    對  $i \in arr$  做
12         $ai \leftarrow$  頂點  $i$  處的代理
13        如果  $ai.intermediate > i$  那麼
14            使用底線引導  $ai$  向右移動, 同時避免阻擋那些
                向左移動的代理
15        別的
16            路線  $ai$  使用上線不停地向左移動
17    同步路徑

```

引理 4.1 (線性合併的性質)。在 $2 \times m$ 的網格上, m 個代理, 從第一個代理開始 row, 可以使用 $Alg.m + o(m)$ 步驟任意排序。2. 靈感來自 merge 種類。運動計畫可在多項式時間內計算。

證明。我們先展示可行性。過程需要 $\log m$ 階段; 在一個階段中, 讓我們表示 $2 \times m$ 網格的一部分, 其中機器人被視為一個區塊。例如, 圖 8(b) 中左邊的 2×4 網格是一個區塊。很明顯, 第一階段最多涉及兩個每個區塊都有機器人是可行的 (即沒有碰撞)。假設階段 k 是可行的, 讓我們看看第 $k + 1$ 階段。

郭&於




圖 8：2 × 8 網格上線性合併洗牌原語的示範。向左走的客服人員總是使用上方通道，而向右走的客服人員總是使用下方通道。

至 $2k+1$ 。對於這樣的區塊，長度達到 2^k 的左半塊已經根據需要完全排序，例如，按照從左到右的遞增順序。對於 $k+1$ 階段，左半塊中的所有機器人只能留在原地或向右移動。這些留下的機器人必須全部位於半塊的最左邊位置，並且不會阻擋任何其他機器人的移動。

對於需要向右移動的機器人，它們的相對順序不需要改變，因此不會造成它們之間的碰撞。由於這些在左半塊中移動的機器人將在網格上向下移動一條邊，因此它們不會干擾右半塊中的任何機器人。因為相同的參數適用於右半塊（方向改變除外），所以合併區塊的整個過程不會發生碰撞。

接下來，我們檢查完工時間。對於任何單一機器人 r ，在階段 k ，假設它屬於 b 。很明顯，如果 r 無法移動到塊 b ，塊 b 要與塊 b 合併超過 $\text{len}(b)$ （可能會產生 b 步，因為機器人需要在網格上向下移動然後向上移動一條邊。這）+ 2 步驟，其中 $\text{len}(b)$ 是 b 的列數，和 2 個額外的。是因為 r 需要做的任何移動都是允許機器人從 b 向 b 移動，因為在任何階段都沒有碰撞，所以將所有階段相加，沒有機器人移動超過 $m + 2(\log m + 1) = m + o(m)$ 步。

最後，類似合併排序的線性合併洗牌原語運行時間為 $O(m \log m)$ ，因為它是具有 $\log m$ 階段的標準分而治之例程。□

我們區分 $\frac{1}{13}$ 和 $\frac{1}{12}$ 密度設置，因為 GRLM 的開銷較大。藥劑密度然而，透過線性合併，GRH 的漸近性質大部分都轉移到了 GRLM。 $\frac{1}{13}$

定理 4.4（隨機 MAPF，代理密度）。對於 $m_1 \times m_2$ 網格上的隨機 MAPF 實例，其中 $m_1 \geq m_2$ 是 2 的倍數，對於 $\leq n \leq \text{代理}$ ，可以在多項式時間內計算出具有高機率的 makespan $m_1 + 2m_2 + o(m_1)$ 的解決方案。當 $m_1 \rightarrow \infty$ 時，解以高機率接近最優性 $1 + \epsilon$ （ $1, 1.5$ ）。

$$\frac{\text{平方米}}{\text{米}^2 + \text{米}^2}$$

證明草圖。結合命題 5.1 和引理 4.1 進行證明。□

4.3 支援網格上任意 MAPF 實例

我們現在研究將 GRH 應用於任意 MAPF 實例，直到達到代理密度。如果 MAPF 實例是任意的，則對 GRH 的所有變更都是完成未標記的重新配置階段所需的完成時間。在 $m_1 \times m_2$ 網格上，透過計算匹配，可以直接證明從任意起始配置開始，只需 $m_1 + m_2$ 步驟即可完成未標記的重新配置階段。由於需要執行兩次未標記的重新配置，因此這會增加 $2(m_1 + m_2)$ 的額外完工時間。因此，以下結果成立。

定理 4.5（任意 MAPF， $\leq m_1 \times m_2$ 網格密度）對於代理程式上的任意 MAPF 實例， $3m_1 + 4m_2 +$ 格， $m_1 \geq m_2$ 對於 $n \leq$ 在多項式 $\frac{m_1 m_2}{12}$ $O(m_1)$ 完工時間解決方案可以在時間內計算。

5. 推廣到 3D

我們現在探索 3D 設定。為了保持討論的重點，我們主要展示如何將 GRH 推廣到 3D，但請注意，GRM 和 GRLM 也可以類似地推廣。

高維度 GRP (Szegedy & Yu, 2023) 定義如下。

問題 2（以 kD 為單位的網格重排 (GRPKD)）設 M 為 $m_1 \times \dots \times m_k$ 表， $m_1 \geq \dots \geq m_k$ ，包含 $i=1$ 到 m_i 個項目，每個表格儲存格中有一個。在混洗操作中， M 的第 i 維（ $1 \leq i \leq k$ ）中單列中的項目可以任意排列。

給定 M 上項目的兩個任意配置 S 和 G ，找到將 M 從 S 到 G 的洗牌序列。

我們可以透過將 GRP 視為 GRP2D，使用 GRA2D 作為子程式來求解 GRP3D。如果我們將 GRA2D 的 2D 切片視為「寬」列，則這很簡單。例如，對於 $m_1 \times m_2 \times m_3$ 網格，我們可以將第二維和第三個維度視為單一維度。

然後，每個寬列本身就是一個 $m_2 \times m_3$ 2D 問題，可以透過應用 GRA2D 重新配置。透過一些適當的計數，我們得到定理 2.2 的 3D 版本，如下所示。

定理 5.1（網格重排定理，3D）。 $m_1 \times m_2 \times m_3$ 表上的任意網格重新排列問題可以使用 $m_1 m_2 + m_3(2m_2 + m_1) + m_1 m_2$ 洗牌來解決。

儘管 (Szegedy & Yu, 2023) 提供了解決 GRPKD 的廣泛框架，但它並不直接適用於高維空間中的多代理路由。為了克服這個限制，我們透過合併和闡述類似於 2D 場景的基本原理，開發了高維 MAPF 演算法。將定理 5.1 的相應演算法表示為 GRA3D，我們說明它如何在 $3 \times 3 \times 3$ 表上運作（圖 9）。

GRA 分三個階段運作。首先，基於初始表建構二分圖 $B(T, R)$ ，其中分集 T 是表示所需 (x, y) 位置的項目的顏色，集合 R 是 (x, y) 的集合項目的位置（圖 2（b））。邊緣的添加方式與 2D 情況相同。根據 $B(T, R)$ ，計算 m_3 個完美匹配。每個匹配包含 $m_1 m_2$ 條邊，並將所有 T 連接到所有 R 。之後

m1m2 z-shuffles的第一階段，中間表（圖 9(c)）可以透過應用帶有m1 x-shuffles 和m2 y-shuffles 的 GRA2D 來重新配置。這會將每個項目排序在正確的xy位置（圖 2(d)）。然後，另一個m1m2 z-shuffle 可以將每個項目排序到其所需的z 位置（圖 2(e)）。




圖 9：應用 GRA3D 的圖示。(a) 初始 $3 \times 3 \times 3$ 表格，隨機排列 27 個有顏色和標籤的項目。顏色代表項目的(x, y)位置。(b) 建構的二分圖。右分集包含所有可能的(x, y) 位置。它包含 3 個完美匹配，確定 (c) 中的 3 列。(c)根據配對結果，對 (a) 套用 z 洗牌，得到一個中間表，其中每個xy平面都有一個顏色恰好出現一次。(d) 對 (c) 套用寬洗牌，依照項目的(x, y) 值（或顏色）正確放置項目。(e) 額外的z 軸完全洗牌

對標記的項目進行排序。

5.1 將 GRH 擴展到 3D

藻類。3、調用Alg。4和阿爾格。圖 5 概述了將 GRH 擴展到 3D 的高階流程。在每個xy平面中，G被劃分為 3×3 個單元（例如圖 7）。不失一般性，我們假設m1、m2、m3是3的倍數且沒有障礙。首先，為了使 GRA3D 適用，我們將任意開始/目標配置轉換為中間平衡配置S1和G1，將代理視為未標記，就像我們在 GRH 中所做的那樣，其中每個2D 平面，每個 3×3 單元包含不超過3 個代理程式（圖10）。

然後可以應用 GRA3D 來協調智能體向中間目標位置G1 移動。函數MatchingXY找到可行的中間配置S2，並透過模擬沿z軸的洗牌操作將代理程式路由到S2。函數XY-Fitting沿著x和y軸應用隨機操作，將每個代理路由到其所需的xy位置（g1i.x，g1i.y）。最後，呼叫函數Z-Fitting，透過沿著z軸執行洗牌操作並連接由無標籤 MAPF 規劃器 UnlabeledMRPP 計算的路徑，將每個代理路由到所需的g1i。

Low-Poly 時間內網格上預期的 1.x-Makespan-Optimal MAPF




圖 10 :套用未標記的 MAPF 將隨機配置轉換為平衡配置
以 $6 \times 6 \times 3$ 網格為中心。

演算法3 :GRH3D	
輸入 :起始頂點和目標頂點 $S = \{s_i\}$ 且 $G = \{g_i\}$	
1	函數GRH3D(S, G) :
2	$S1, G1 \leftarrow$ 未標記MRPP(S, G)
3	匹配XY()
4	XY-擬合()
5	Z-型配件()

現在我們來解釋一下GRH3D的各個部分。MatchingXY使用 GRA 的擴展版本來尋找允許可行的洗牌操作的完美匹配。這裡，項目（代理）的「項目顏色」是元組($g1i.x, g1i.y$)，這是它需要去的所需xy位置。應用沿z方向的洗牌操作將代理移動到S2，我們需要對每個平面中的這些代理應用GRA2D。是其所需的x位置 $g1i.x$ 。對於每個平面，我們計算m2個完美匹配以確定中間位置 $g2$ 。然後每個智能體透過應用y-shuffle 操作移動到它的 $g2i$ 。在第 18 行中，透過執行x-shuffle 操作將每個代理程式路由到其所需的x位置。在第 19 行中，透過執行y-shuffle 操作將每個代理程式路由到其所需的y位置。當所有智能體到達所需的xy位置後，Z-Fitting中的另一輪z-shuffle 操作可以將智能體路由到由未標記的 MAPF 規劃器計算的平衡目標配置。最後，我們將所有路徑連接起來作為結果。

GRLM 和 GRM 可以透過取代 2D 平面中的求解器以類似的方式擴展到 3D。對於 GRM，無需使用未標記的 MAPF 進行平衡重新配置，這會產生 $4m1 + 8m2 + 8m3$ 的完工上限（作為定理 3.1 和定理 5.1 的直接組合）。對於 3D 中半密度以下的任意實例，定理 4.5 中的完工保證更新為 $3m1 + 4m2 + 4m3 + o(m1)$ 。

演算法 4 :匹配XY

輸入 :平衡的起始頂點和目標頂點 $S1 = \{s1i\}$ 且 $G1 = \{g1i\}$

1函數匹配XY($S1, G1$): $2 A \leftarrow [1, ..., n]$

3 $T \leftarrow S1$ 中的 (x, y) 位置集合for $(r, t) \in T \times T$ do if $\exists i \in A$ 其中

4 $(s1i.x, s1i.y) = r \wedge (g1i.x, g1i.y) = t$ 然後將邊 (r, t) 加到 $B(T, R)$ 從 A 刪除 i

5

6

7

8 計算 $B(T, R)$ 的匹配 $M1, ..., Mm3$

9 $A \leftarrow [1, ..., n]$ foreach

10 Mc and $(r, t) \in Mc$ do if $\exists i \in A$ where

11 $(s1i.x, s1i.y) = r \wedge (g1i.x, g1i.y) = t$ 則 $s2i \leftarrow (s1i.x, s1i.y, c)$ 並從 A 移

12 除 i 標記代理 i 前往 $s2i$

13

14 平行執行模擬 z 洗牌

演算法 5 :XY 擬合

輸入 :目前位置 $S2$ 和平衡目標位置 $G1$

1函數 XY-Fitting(): 為 $z \leftarrow [1, ...,$

2 $m3]$ do $A \leftarrow \{i | s2i.y = z\}$

3

4 $GRH2D(A, z)$

5函數 $GRH2D(A, z)$:

6 $T \leftarrow S2$ 的 x 位置集合 ,對於 $(r, t) \in T \times T$ do

7

8 if $\exists i \in A$ 其中 $s2i.x = r \wedge g1i.x = t$ 那麼如果代理 i 未

9 分配 ,則將邊 (r, t) 加到 $B(T, R)$ 標記 i 已

10 分配

11

12 計算 $B(T, R)$ 的匹配 $M1, ..., Mm2$

13 $A' \leftarrow A$

14 foreach Mc 和 $(r, t) \in Mc$ 執行 if $\exists i \in A'$ where

15 $s2i.x = c \wedge g1i.x = t$ then $g2i \leftarrow (s2i.x, c, z)$ 並從 A 中刪除

16 標記代理 i 前往 $g2i$

17 號

18 將每個代理人 $i \in A$ 路由到 $g2i$ 將每

19 個代理人 $i \in A$ 路由到 $(g2i.x, g1i.y, z)$ 將每個代

20 理人 $i \in A$ 路由到 $(g1i.x, g1i.y, z)$

5.2 GRH3D 的特性

GRH3D 的計算以完美匹配和未標記 MAPF 為主。尋找 m_3 「寬列」匹配需要 $O(m_3 m_2 \log m_2)$ 確定性時間或 $O(m_3 m_2 \log(m_1 m_2))$ 預期時間。我們應用 GRA2D 來模擬「寬列」洗牌，這需要 $O(m_3 m_2 \log m_1)$ 確定性時間或 $O(m_1 m_2 m_3 \log m_1)$ 預期時間。因此，網絡重新排列部分的總時間複雜度為 $O(m_3 m_2 \log m_2 + m_2 \log m_3)$ 。對於未標記的 MAPF，我們可以使用基於最大流量的演算法（Yu & LaValle，2013a）來計算完工時間最優解。最大流量部分可用 $O(n|E|T) = O(n(m_1 + m_2 + m_3))$ 求解，其中 $|E|$ 是邊數， $T = O(m_1 + m_2 + m_3)$ 是時間擴展圖的時間範圍（Ford & Fulkerson，1956）。也可以執行兩次「寬列」洗牌加上一個 z 洗牌，這會產生 $2(2m_1 + m_2) + m_3$ 洗牌次數和 $O(m_1 m_2 m_3)$ 。這需要更多的洗牌，但運行時間更短。

接下來，我們推導出最優保證，其中上界和下界需要完工時間。這些都是二維結果的直接概括。

定理 5.2（完工上限）。GRH3D 在 3D 網絡上以高機率傳回具有 $m_1 + 2m_2 + 2m_3 + o(m_1)$ 漸近完工時間的 MAPF 實例的解，其中 $m_1 m_2 m_3$ 隨機開始和目標配置。GRM3D 在 3D 網絡上以高機率傳回具有 $m_1 + 2m_2 + 2m_3 + o(m_1)$ 漸近完工時間的 MAPF 實例的解，其中 $m_1 m_2 m_3$ 隨機開始和目標配置。GRM3D 在 3D 網絡上以高機率傳回具有 $3m_1 + 6m_2 + 6m_3 + o(m_1)$ 漸近完工時間的 MAPF 實例的解決方案，其中 $m_1 m_2 m_3$ 隨機開始和目標配置。此外，如果 $m_1 = m_2 = m_3 = m$ ，GRH3D 和 GRM3D 傳回 $5m + o(m)$ 完工時間的解，GRM3D 會回傳 $15m + o(m)$ 完工時間的解。

命題 5.1（完工時間下限）。對於 $m_1 \times m_2 \times m_3$ 網絡上的 MAPF 實例，在 3D 網絡上具有 $\theta(m_1 m_2 m_3)$ 隨機起始和目標配置，完工時間下界以高機率漸近逼近 $m_1 + m_2 + m_3$ 。

定理 5.3（完工時間最優比）。GRH3D 和 GRM3D 產生漸進 $m_2 m_3 \log m_1 + m_1 + m_2 + m_3$ 漸近完工時間的 MAPF 實例的 makespan 最優比，且 $\leq \frac{m_1 m_2 m_3}{m_1 + m_2 + m_3}$ 。GRM3D 在 3D 網絡上以高機率產生 $\theta(m_1 m_2 m_3)$ 漸近完工時間的 MAPF 實例的漸近最優比。

我們可以進一步將結果推廣到更高的維度。

定理 5.4。考慮網絡大小為 m 的 k 維立方網絡。對於均勻分佈的起始和目標配置，GRH 和 GRM 可以求解具有 $4(2k-1+1) \frac{m}{k} + 1$ 漸近完工時間最優性的實例，並且 GRM 產生漸近完工時間最優性。

證明。未標記的 MAPF 需要 $o(m)$ 的完工時間（注意 $k \geq 3$ ，最小最大網絡匹配距離為 $O(\log 1/km)$ ）（Shor & Yukich, 1991）。將命題 5.1 推廣到 k 維網絡，漸進下界為 mk 。我們以歸納法證明漸近完工時間 $f(k)$ 為 $(2k-1+1)m + o(m)$ 。網絡重排演算法求解 k 維

郭&於

透過使用兩個一維洗牌和一個(k-1) 維「寬列」洗牌來解決問題。

因此，我們有f(k) = 2m+f(k-1) 很容易看出f(1) = m+o(m), f(2) = 3m+o(m), 2 k-1+1得f(k) = 2k-1m + m + o(m)和k的完工時間最優比

GRH 與 GRLM 同時k $\frac{4(2k-1+1)}{k}$ 對於GRM。 □

6. 最佳化啟發法

6.1 透過優化匹配縮短完工時間

GRH在GRA的基礎上，模擬了三個shuffle階段。完成時間由需要最長移動時間的代理人決定，作為所有三個階段的移動總和。因此，網格重排方法的最適性由第一個準備/匹配階段決定。找到任意完美匹配的速度很快，但可以改進該過程以縮短整體完工時間。

為了改善匹配，我們提出了兩種啟發式方法；第一個是基於整數規劃（IP）。我們建立二元變數{xri}，其中r代表行號，i代表代理。如果xri = 1，則將代理i指派給第r行。+ (1 - λ)|r - gi.x|。我們透過讓λ = 0 來優化第一階段的完成時間下界，或透過讓λ = 1來優化第三階段。

$$\max_{r,i} \{C_{ri}(\lambda = 0)x_{ri}\} + \max_{r,i} \{C_{ri}(\lambda = 1)x_{ri}\} \tag{1}$$

$$x_{ri} = 1 \text{ , 對於每個代理 } i \tag{2}$$

$$x_{ri} \leq 1 \text{ , 對於每行 } r \text{ 和每種顏色 } t \tag{3}$$

$$g_i.y=t$$
$$x_{ri} = 1 \text{ , 對於每列和每行 } r \tag{4}$$

$$s_i.x=c$$

等式。(1)是第一階段和第三階段的完工時間下限之和。請注意，第二階段無法透過優化匹配來改進。等式。(2)要求代理i只出現在一排。等式。(3)指定每行應包含具有不同目標列的代理程式。等式。(4)規定每個頂點(r, c)只能分配給一個代理人。IP 模型代表了一般的 NP 困難的一般分配問題。它的可擴展性有限，但提供了一種評估匹配在極限情況下的最佳程度的方法。

我們開發的第二個匹配啟發式是基於線性瓶頸分配(LBA)（Burkard、Dell Amico 和 Martello，2012），這需要多項式時間。LBA與 IP 啟發式的差異在於二分圖是加權的。對於分配給第r 行的匹配，貪婪地計算二部圖的邊權重。如果c列包含顏色為t的代理，我們添加一條邊 (c，t)，其邊成本為

$$C_{ct} = \min_{g_i.y=t} C_{ri}(\lambda = 0) \tag{5}$$

我們選擇λ = 0 來優化第一階段。優化第三階段(λ = 1) 將會得到類似的結果。構造加權二部圖後， $O(\frac{m^{2.5}}{\log m})$ LBA

Low-Poly 時間內網絡上預期的 1.x-Makespan-Optimal MAPF

應用演算法 (Burkard et al., 2012)來獲得行r 的最小瓶頸成本匹配。然後我們刪除分配的代理並計算下一行的下一個最小瓶頸成本匹配。得到所有符合的Mr 後，我們可以進一步使用 LBA 將Mr分配到不同的行以獲得更小的 makespan 下界。將匹配Mr分配給第 r 行的成本定義為 $CM_{rr'} = \max_{i \in M_r} C_{ri}$

$$C_{r'}(\lambda = 0) \tag{6}$$

使用LBA啟發式進行配對的總時間複雜度為 $O\left(\frac{m^{3.5}}{\log m}\right)$ 。

我們將 IP 和 LBA 啟發式的 GRH 分別表示為 GRH-IP 和 GRH-LBA。

我們提到，GRM 使用線交換運動原語，也可以從這些啟發式中受益，以重新分配每個組內的目標。這可以降低瓶頸路徑長度並提高最優性。

6.2 路徑細化

基於 GRA 的演算法的最終路徑是來自多個規劃階段的路徑的串聯。這意味著智能體被迫在階段邊界“同步”，這會導致提前完成階段的智能體不必要的空閒。注意到這一點，我們取消了規劃階段的同步，這在完工時間優化方面產生了顯著的效益。

我們的路徑細化方法與最小通訊策略（MCP）(Ma, Kumar, & Koenig, 2017a)類似，這是一種多代理執行策略，旨在處理意外延遲而不停止未受影響的代理。在執行過程中，MCP 讓智能體儘早執行下一個非空閒移動，同時保留智能體之間的相對執行順序，例如，當兩個智能體需要在不同時間進入同一頂點時，會保留該順序。

我們採用 MCP 中使用的原理來細化基於 GRA 的演算法產生的路徑，如 Alg 所示。6 與阿爾格。7作為子程序。該演算法的工作原理如下。

所有空閒狀態都從初始代理程式中刪除，但保留每個頂點的存取順序（第 2-3 行）。然後我們進入一個循環，執行遵循 MCP 原則的計劃（第 8-10 行）。在阿爾格. 7.如果i是下一個依照原始順序進入頂點vi 的智能體，我們檢查目前vi處是否有智能體。如果沒有，我們讓我輸入vi。如果另一個代理目前正在佔用vj，我們透過遞歸呼叫函數Move 來檢查是否在下一個步驟中移動到其下一個頂點vj。我們檢查下一個原始計劃中的代理動作是否有循環。如果i在一個循環中，我們將這個循環中的所有代理遞歸地移動到下一個頂點（第 20-28 行）。如果沒有找到循環並且將進入其下一個頂點vj，我們讓i也移動到其下一個頂點vi。否則，我應該在ui等待。此演算法在構造上是無死鎖的（Ma et al., 2017a）。

設T為初始路徑的makespan，運行Refine得到的解的makespan顯然不會超過T。其時間複雜度為O(n)，因此路徑細化的時間複雜度以O(nT)為界。

原則上也可以應用其他路徑細化方法，例如（Li, et al., 2021a; Okumura, Tamura, & Défago, 2021），它迭代地選擇一小群智能體並重新規劃其包含其他智能體的路徑作為動態障礙。然而，在我們處理的密集環境中，重新規劃一小群智能體幾乎不可能以這種方式找到更好的路徑。

演算法 6 :路徑細化

```
輸入 :GRA產生的路徑P
1函數細化(P):
2   foreach v ∈ V      , V 順序[v] ← 佇列()
3   預處理 (初始計劃 \V 順序)
4   雖然是真的
5   |   對於 i = 1...n 做
6   |   |   移動 ← Dict()
7   |   |   循環檢查 ← 設定()
8   |   |   移動 (一)
9   |   |   如果 AllReachedGoals()==true 那麼
10  |   |   |   休息
```

演算法 7 :移動

```
1函數移動(i):
2   如果我搬家了那麼
3   |   返回已移動[i]
4   ui ← i 的目前位置
5   vi ← i 的下一個位置
6   如果 i = V Order[vi ].front() 那麼
7   |   j ← 目前在vi 的代理
8   |   如果我在 CycleCheck 那麼
9   |   |   在迴圈中移動所有代理(i)
10  |   |   回傳真
11  |   CycleCheck.add(i)
12  |   如果 Move(j) = true 或 j =None 那麼
13  |   |   讓我輸入vi
14  |   |   V Order[vi ].popfront()
15  |   |   已移動[i] ←true
16  |   |   回傳真
17 讓我在ui等
18 移動[i]=假
19 回傳錯誤

20函數 MoveAllAgentsInCycle(i):
21訪問 ← Set()
22   j ← 我
23   當 j 不在訪問時
24   |   讓j進入它的下一個頂點vj
25   |   訪問.add(j)
26   |   V Order[vj ].popfront()
27   |   已移動[j] ← true
28   |   j ← 目前位於頂點vj 的智能體
```

7. 模擬實驗

我們徹底評估了基於 GRA 的演算法，並將其與許多類似的演算法進行了比較。我們主要強調與 EECBS ($w=1.5$) (Li, Ruml, & Koenig, 2021b)、LaCAM (Okumura, 2023) 和 DDM (Han & Yu, 2020) 的比較。據我們所知，這兩種方法是最快的近乎最佳 MAPF 求解器中的兩種。除了 EECBS 和 DDM 之外，我們還考慮了一種最先進的多項式演算法，堆入交換 (Push-and-swap) (Luna & Bekris, 2011)，它給出了相當次優的結果。對於密度來說，完工時間最適性比率通常高於 100 我們檢查。

作為本節的讀者指南，在第 2 節。7.1，作為熱身，我們展示了所有基於 GRA 的演算法在其基線上的 2D 性能，即沒有第 7 節中提到的任何提高效率的啟發式方法。6. 在秒中。7.4，對於 2D 方形網絡，我們展示了所有基於 GRA 的演算法在使用和不使用第 7 節中討論的兩種啟發式方法的情況下的性能。6. 然後，我們在第 2 秒中全面評估了所有版本的 GRH 2d 演算法在代理密度下的表現。7.2. 一些特殊的 2D 圖案將在第 2 節中進行研究。7.3. 3D 設定將在第 2 節中簡要討論。7.5。

13

所有實驗均在 3.2GHz 的 Intel® Core™ i7-6900K CPU 上進行。除非另有說明，每個數據點都是隨機產生的實例上 20 多次運行的平均值。所有實例的運行時間限制均為 300 秒。與保守估計的完工時間下限相比，估計最優比率。所有演算法都是用 C++ 實作的。我們選擇 Gurobi (Gurobi Optimization, LLC, 2021) 作為混合整數規劃求解器，選擇 ORtools (Perron & Furnon,) 作為最大流求解器。

7.1 基於 GRA 的方法的基線版本的最適性

首先，我們對 GRM、GRLM 和 GRH 的基本版本在最大設計代理密度下隨機產生的 2D 實例所實現的最適性進行了總體評估。也就是說，這些方法不包含第 2 節的啟發式方法。6. 我們測試了三種 $m1:m2$ 比率：1:1、3:2 和 5:1。結果如圖 11 所示。我們稍後提供 GRH 的計算時間；GRM、GRLM 和 GRH 的運行時間都相似。最優比率計算為解決方案完成時間與任何一對起點和目標之間的最長曼哈頓距離之間的比率，該距離是保守的。

當子網絡大小從 3×2 、 3×3 、 2×3 和 2×4 變化到略高於 3 時，GRM 在最優比上做得越來越好。子網絡洗牌會降低最優比，因為有機會減少開銷。然而，隨著子網絡大小的增加，計算所有可能配置的解決方案所需的時間呈指數增長。

另一方面，GRLM 和 GRH 在大多數測試案例中都實現了低於 2 的最優比，其中 GRH 在大型網絡上的結果降至 1.5 以下。對於所有設置，隨著網絡大小的增加，所有方法/網絡縱橫比的最適性都有提高的總體趨勢。這是由於兩個原因：(1) 隨著網絡大小的增加，洗牌操作的開銷變得相對較小；(2) 隨著代理數量的增加，完工時間下限變得更接近 $m1 + m2$ 。最後，隨著 $m1:m2$ 比率增加，最優比率提高。

郭&於




圖 11 :對於不同的 m_2 值和 $m_1:m_2$ 比率，GRM (3x2、2x3、3x3、2x4)、GRLM 和 GRH 在最大設計密度下的完工最佳化比。最大的 GRM問題在 300 × 300 網格上有 90,000 個代理程式。

正如預測的那樣，對於許多測試案例， $m_1:m_2=5$ 時 GRH 的最優比率約為 1.3。

特工數量 5		10	15	20	25
最優差距	1.1.0025	1.0041	1.0111	1.073	

表 2 :5 × 5 網格的最適性差距調查

最適性差距的探索是在 5 × 5 網格上進行的，如表所示。2。
對於每個指定數量的代理，我們建立 100 個隨機實例並使用 ILP 求解器來求解它們。然後透過計算最佳完工時間和完工時間下限之間的平均比率來評估最適性差距。最適性差距隨著代理密度的增加而擴大。

7.2 GRH的評估與比較研究

7.2.1 網格尺寸的影響

對於我們分別在 100% 密度下對 GRA、GRLM 和 GRH 性能的第一次詳細比較研究，我們在計算時間和完工時間最優比方面設定 $m_1:m_2 = \frac{1}{3}$ 和 $\frac{1}{2}$ 。我們在圖 12-14 中與 DDM (Han & Yu, 2020)、EECBS ($w = 1.5$) (Li et al., 2021b)、Push and Swap (Luna & Bekris, 2011)、LaCAM (Okumura, 2023) 進行比較。對於 EECBS，我們啟用所有可用的啟發式方法和推理。

當代理密度為 100% 時，GRM 方法可以在大約 40 秒內解決巨大的實例，例如在 450 × 300 網格上具有 135,000 個代理，而其他演算法都無法做到這一點。LaCAM 只能解出 $m_2 = 30$ 時的實例，但最終的完工時間最適性約為 2073，因此圖中未顯示。當達到代理密度時，GRLM 和 GRH 仍然是所有方法中最快的，在 10 秒內擴展到 45,000 個代理，而最優比分別接近 1.5 和 1.3。LaCAM 也實現了很好的可擴展性，能夠解決 $m_2 \leq 270$ 時的問題。

Low-Poly 時間內網絡上預期的 1.x-Makespan-Optimal MAPF




圖 12 :不同大小的 $m_1 \times m_2$ 網絡上的計算時間和最適性比率 ,其中 $m_1 : m_2 = 3 : 2$ 且代理密度為 100% 密度。




圖 13 :不同大小的 $m_1 \times m_2$ 網絡上的計算時間與最適性比率
 $m_1 : m_2 = 3 : 2$ 且藥劑密度為 $\frac{1}{2}$ 密度。

記憶體不足錯誤。這是因為 LaCAM 是一種關於聯合配置的搜尋演算法 ,所需的記憶體隨著智能體數量呈指數增長。相較之下 ,GRH 、GRLM 不存在這個問題 ,並且能夠一致地解決問題 ,儘管最適性比 LaCAM 差。EECBS ,在代理密度 $m_2 = 90$ 後停止工作 ,並且在 100% 代理密度的時限內無法解決任何實例 ,

郭&於




圖 14 :不同大小的 $m_1 \times m_2$ 網格上的計算時間和最適性比率 ,其中 $m_1 : m_2 = 3 : 2$ 且代理密度為 $1/3$ 密度。

而DDM在 $m_2=180$ 後就停止運作了。

7.2.2 處理障礙物

GRH還可以處理分散的障礙物 ,特別適合障礙物規則分佈的情況。例如 ,如圖 1(b) 所示的底層圖的問題 ,其中每個 3×3 單元中間都有一個洞 ,可以在不降低效能的情況下本地解決。這種設置在大型倉庫的包裹分揀設施中得到了實際應用 (Wan 等人 ,2018 年 ;Li 等人 ,2020 年) 。對於此包裹分類設置 ,我們將代理密度固定為 ,並在不同大小的圖表上測試 EECBS 、DDM 、GRH 、GRH-LBA 、GRH-PR 、iGRH 。結果如圖15所示。因此 ,我們在地圖上添加了額外的“邊界” ,使其可以透過DDM 進行求解。結果與之前類似 ;我們注意到 iGRH 達到了保守的最適比估計值 1.26。

$$\frac{2}{9}$$

7.2.3 網格縱橫比的影響

在本節中 ,我們固定 $m_1 m_2 = 90000$ 並在 0 (接近一維)和 1 (方形網格)之間改變 $m_2 : m_1$ 比率。我們評估了四種演算法 ,其中兩種是 GRH和 iGRH。現在回想一下 , $m_1 \times m_2$ 表上的 GRP也可以使用 $2m_2$ 列洗牌和 m_1 行洗牌來解決。使用 $m_1 + 2m_2$ 洗牌調整 GRH 和 iGRH給出了另外兩個變體 ,我們將其表示為 GRH-LL 和 iGRH-LL ,其中“LL”表明執行兩組較長的洗牌 (每組列洗牌均使用長度為 m_1 的欄位) 。

結果總結在圖 16 中。

Low-Poly 時間內網格上預期的 1.x-Makespan-Optimal MAPF




圖 15 :不同規模環境的計算時間與最適性比率
障礙物的密度和代理的密度有規律地分佈。 $m1:m2 = \frac{1}{3}:\frac{2}{9}$ 。




圖 16 :不同長寬的矩形網格上的計算時間與最優比
比率和 $\frac{1}{3}$ 藥劑密度。

有趣但並不令人驚訝的是，結果清楚地表明了之間的權衡
計算工作量和解決方案的最優性。GRH 和 iGRH 實現更好的最優比
與 GRH-LL 和 iGRH-LL 相比，但需要更多的計算時間。尤其，
當 $m2:m1$ 接近 0 時，GRH 和 iGRH 的最優比率非常接近 1。
預計 iGRH 的整體表現比 GRH 好得多。

7.3 特殊模式

我們在許多「特殊」實例上試驗了 iGRH，這裡展示了兩個實例（圖 17）。對於這兩個設置，我們設定 $m_1 = m_2$ 。在第一個「正方形」設定中，智能體形成同心方形環，每個智能體及其目標都是中心對稱的。在第二種「區塊」設定中，網絡被劃分為包含相同數量代理的較小的方塊（不一定是 3×3 ）。來自一個區塊的特工需要移動到另一個隨機選擇的區塊。iGRH 在方形設定中實現了相當接近 1.0 的最優性，在區塊設定中則達到了 1.7 的最優性。計算時間與圖 15 類似；EECBS 在最優性方面表現良好，但其可擴展性有限，僅適用於 $m \leq 90$ 的網絡。對於方形圖案的最適性相對較差。其他演算法由於最優性明顯較差而被排除在考慮之外；例如，DDM 的最適性超過 9，Push&Swap 的最適性大於 40。




圖 17：(a) 「方塊」設定的圖示。(b) 「塊」設定的圖示。(c) EECBS、LaCAM 和 GRH-LBA 兩種設定的最適比。

7.4 配對和路徑細化啟發法的有效性


在本小節中，我們評估第 2 節中引入的啟發式方法的有效性。6 提高基於 GRA 的基線方法的效能（稍後我們將簡要介紹 IP 啟發式）。我們展示了 GRM、GRLM 和 GRH 在這些方法的最大設計密度下的表現。對於每種方法，都包含所有 4 種啟發式組合的結果。

對於基準方法 X，X-LBA、X-PR 和 iX 分別表示具有 LBA 啟發式、路徑細化啟發式和兩種啟發式的方法。除了完工時間最適性比率之外，我們還評估了一些讀者可能感興趣的成本總和（SOC）最適性比率。成本總和是各個智能體達到各自目標所採取的步驟數的總和。我們測試了最壞情況，即 $m = m_1 = m_2$ 。

結果如圖 18 所示。

我們根據圖 18 進行了兩個關鍵觀察。%，使完工時間優化性提高了 30% - 40%。

Low-Poly 時間內網絡上預期的 1.x-Makespan-Optimal MAPF

圖 18 :啟發式方法在 $m \times m$ 網絡上增強基於 GRA 的演算法的有效性。

對於所有圖中，x 軸是網絡邊長 m 。每行顯示一個特定的演算法（GRM、GRLM 和 GRH）。從左到右，完工時間(MKPN)最優比、SOC 最優比以及所需的計算時間給出了路徑細化例程。

其次，兩種啟發式的綜合效果幾乎是相加的，證實了正如它們的設計所表明的那樣，兩個啟發式是彼此正交的。最終結果是全面的整體最適性顯著提高。例如，對於 GRH，對於最後一個數據點，完工時間最適性比率從1.8左右下降到 iGRH約為1.3。就計算成本而言，LBA 啟發式增加的計算成本可忽略不計更多時間。路徑細化啟發式在完整和密度設定中需要更多時間，但是增加了很少的成本 $\frac{1}{3}$ 密度設定。

 $\frac{1}{2}$

7.5 3D網絡評估

對於 3D 設置，我們方法的性能和解決方案結構在很大程度上相似到 2D 設定。因此，我們提供完整性的基本評估，修復方面比率 $m_1:m_2:m_3=4:2:1$ 和密度，並檢查 GRH3D 變體 $\frac{1}{3}$ ，不同尺寸的無障礙網絡。這裡，因為DDM只適用於2D，所以我們使用ILP

使用分割啟發式 (Yu & LaValle, 2016) 而不是 DDM。開始和目標配置是隨機產生的，結果如圖 19 所示。相較之下，GRH3D 變體很容易擴展到具有超過 370,000 個頂點和 120,000 個代理程式的網絡。GRH 變體的最優比隨著網絡大小的增加而降低，接近 1.5-1.7。




圖 19 :四種方法在不同網絡大小且 $m1 : m2 : m3 = 4 : 2 : 1$ 的 $m1 \times m2 \times m3$ 網絡上的計算時間與最優比。

八、結論與討論

在本研究中，我們建議應用網絡重新排列 (Szegedy & Yu, 2023) 來解決 MAPF。

GRA 的基本改編加上更有效率的線洗牌例程，能夠在多項式時間內以最大代理密度求解網絡上的 MAPF，並提供以前無法實現的最優性保證。然後，結合 GRA、高速公路啟發式和附加匹配啟發式，我們獲得新穎的多項式時間演算法，該演算法可證明漸近代理密度，具有高 $1 + \epsilon$ 機率。在存在障礙且代理密度高達二分之一的情況下也能實現類似的保證。這些 2D 結果很容易推廣到 3D 和更高維度。在實踐中，我們的方法可以解決具有超過 105 個頂點和 4.5×10^4 個智能體的 2D 圖上的問題，達到 1.26 makespan 最優（使用更大的 $m1 : m2$ 比率可能會更好）。

知， $\frac{m2}{m1+m2}$ 使跨距在 $m1 \times m2$ 網絡上達到最優，最多可達 $\frac{1}{13}$ 3D 中的可擴展性甚至更好。據我們所先前的 MAPF 解算器都沒有提供低多項式運行時間和實際最優性的雙重保證。

限制 雖然 GRA 擅長在密集實例的多項式時間內實現相當好的最優性，但當應用於具有少量機器人或本質上易於解決的實例的場景時，它確實存在局限性。在這種情況下，儘管 GRA 仍然有效，但其性能可能落後於其他演算法，並且與更專業或更有效的方法相比，其解決方案可能不是最佳的。

該演算法的優勢在於能夠利用其獨特的方法有效地處理複雜、人口密集的场景。然而，用戶應該注意它在更簡單的情況下的相對性能，在這些情況下替代演算法可能提供更好的解決方案。

這個限制強調了在選擇最佳化演算法、調整選擇以匹配給定問題實例的複雜性時考慮機器人系統和手頭任務的具體特徵的重要性。

我們的研究為許多後續研究方向打開了大門；我們在這裡討論一些。

新的行洗牌例程。目前，GRLM和GRH僅使用兩/三行來執行模擬行洗牌。除其他限制外，這要求用於執行模擬洗牌的子網格連接良好（即無障礙物或障礙物規則間隔，以便每個運動單元中至少有兩行不被靜態障礙物阻擋）來模擬隨機播放）。在模擬行洗牌中使用更多行或不規則行，可以容納更大的障礙物和/或高於二分之一的支撐密度。

以較低的代理密度實現更好的最佳化。有趣的是，檢查是否可以在較低的代理密度設定（例如，密度或甚至更低的密度）下實現進一步的最優性增益，這仍然非常實用。我們假設這可以透過以某種方式合併 GRA 的不同階段來實現，以便在計算初始計劃後可以消除一些不必要的代理旅行。

考慮更現實的機器人模型。目前的研究假設一個單位成本模型，其中代理人花費單位時間行進單位距離，並允許在每個整數時間步長轉彎。在實踐中，機器人需要加速/減速，還需要轉彎。如果使用上述單位成本模型計算原始計劃，轉向可能會特別成問題，並導致計劃執行時間顯著增加。我們注意到，GRH 返回的解決方案中機器人大部分時間都沿著直線移動，這與所有現有的 MAPF 演算法（例如 ECBS 和 DDM）相比是有利的，這些演算法的計算計劃有許多方向變化。隨著更真實的機器人模型的採用，基於 GRA 的 MAPF 演算法的性能是否會進一步提高，這將是一件有趣的事情。

備註 1. 目前，我們基於 GRA 的 MAPF 求解僅限於靜態設置，而多智能體運動規劃的電子商務應用通常需要求解終身設置（Ma 等人，2017b）。評估終身 MAPF 的指標通常是吞吐量，即每個時間步達到的目標數量。我們注意到，GRH 也為此類設定提供了最優性保證，例如，對於 $m_1 = m_2 = m$ 的設置，GRH 直接應用於方形網格上的大規模終身 MAPF 會產生吞吐量的最優比。

$$\frac{2}{9} \text{ 在}$$

我們可以使用 GRH 批次解決終身 MAPF。每批有 n 個代理，GRH 大約需要 $3m$ 步驟，則吞吐量為 $\text{TRT} \approx \frac{n}{3m}$ 。至於吞吐量的下限估計，在 $m \times m$ 的正方形中，忽略代理間衝突的預期曼哈頓距離為 3 。因此，每個批次的下限吞吐量為 $\text{Tlb} = \frac{n}{3m}$ ，漸近最優性比率為 $\frac{\text{TRT}}{\text{Tlb}} \approx 9$ 。該估計值相當保守，因為 GRH 支援已知的終身 MAPF 解算器所不支援的更高的代理密度。

$$\frac{3n}{2m}。$$

$$\frac{\text{吞吐量}}{\text{期望值}} = \frac{2}{9}$$

因此，開發一種受網格重排啟發的最佳化演算法來解決終身 MAPF 問題似乎非常有希望。

致謝

這項工作得到了 NSF 獎 IIS-1845888、CCF-1934924、IIS-2132972 和 CCF-2309866 以及亞馬遜研究獎的部分支持。

參考

Banfi, J., Basilico, N. 與 Amigoni, F. (2017). 帶孔二維網格圖上時間最優多機器人路徑規劃的難處理性。IEEE 機器人與自動化快報, 2 (4), 1941–1947。

Barer, M., Sharon, G., Stern, R. 與 Felner, A. (2014). 用於多智能體尋路問題的基於衝突的搜尋演算法的次優變體。第七屆組合搜尋年度研討會。

Bitton, D., DeWitt, DJ, Hsaio, DK 與 Menon, J. (1984). 並行排序的分類法。ACM 計算調查 (CSUR), 16 (3), 287–318。

Burkard, R., Dell'Amico, M. 與 Martello, S. (2012). 作業問題。修改重印。

Damani, M., Luo, Z., Wenzel, E. 與 Sartoretti, G. (2021). 原始_2: 透過強化和模仿多智能體終身學習進行尋路。IEEE 機器人與自動化快報, 6 (2), 2666–2673。

De Wilde, B., Ter Mors, AW 與 Witteveen, C. (2014). 推送與旋轉: 完整的多智能體尋路演算法。人工智慧研究雜誌, 51, 443–492。

Dekhne, A., Hastings, G., Murnane, J. 與 Neuhaus, F. (2019). 物流自動化: 大機遇, 更大的不確定性。麥肯錫 Q, 第 1–12 頁。

Demaine, ED, Fekete, SP, Keldenich, P., Meijer, H. 與 Scheffer, C. (2019). 協調運動規劃: 重新配置一群具有有限伸展的標記機器人。SIAM 計算雜誌, 48 (6), 1727–1762。

Erdem, E., Kisa, DG, Oztok, U. 和 Schüller, P. (2013). 用於多個智能體尋路問題的通用正式框架。第二十七屆 AAAI 人工智慧大會。

Erdmann, M. 與 Lozano-Perez, T. (1987). 在多個移動物體上。演算法, 2 (1), 477–521。

福特, LR 和富爾克森, DR (1956). 通過網路的最大流量。加拿大雜誌數學, 8, 399–404。

Goel, A., Kapralov, M. 與 Khanna, S. (2013). 正規二部圖中在 $o(n \log n)$ 時間內完美匹配。SIAM 計算雜誌, 42 (3), 1392–1404。

Goldenberg, M., Felner, A., Stern, R., Sharon, G., Sturtevant, N., Holte, RC 與 Schaeffer, J. (2014). 增強型局部擴展 a。人工智慧研究雜誌, 50, 141–187。

戈爾德賴希 ·O. (2011) 。在圖廣義 15 謎題中找出最短的移動序列是 np 困難的 。在複雜性和密碼學研究中 。關於隨機性和計算之間交互作用的雜記 ,第 1-5 頁 。施普林格 。

郭 T. 、馮 SW 和 Yu J. (2022) 。三維多項式時間近時最優多機器人路徑規劃及其在大規模無人機協調的應用 。 2022 年 IEEE/RSJ 國際智慧機器人與系統會議 (IROS) ,第10074–10080 頁 。

郭 T. 、韓 SD 與 Yu J. (2021) 。用於多機器人運動規劃的空間和時間分割啟發式 。在 IEEE 國際機器人與自動化會議上 。

郭 T. 與 Yu J. (2022) 。多項式時間內網格上的 Sub-1.5 時間最優多機器人路徑規劃 。《機器人學報 :科學與系統》 ,美國紐約州紐約市 。 DOI :10.15607/RSS.2022.XVIII.057 。

Gurobi Optimization, LLC (2021) 。 Gurobi 優化器參考手冊.. <https://www.gurobi.com> 。

霍爾 ·P. (2009) 。關於子集的代表 。組合學經典論文 ,第 58-62 頁 。

施普林格 。

Han, SD 、Rodriguez, EJ 與 Yu, J. (2018) 。 Sear :一種多項式時間多機器人路徑規劃演算法 ,具有預期的常數因子最適性保證 。 2018 年 IEEE/RSJ 智慧機器人與系統國際會議 (IROS) ,第 10 頁 。

1-9 。 IEEE 。

Han, SD 與 Yu, J. (2020) 。 Ddm :使用多樣化路徑和最優子問題解決方案資料庫啟發式的快速近最優多機器人路徑規劃 。 IEEE 機器人與自動化快報 ,5 (2), 1350–1357 。

Hönig, W. 、Preiss, JA 、Kumar, TS 、Sukhatme, GS 和 Ayanian, N. (2018) 。四旋翼飛行器群的軌跡規劃 。 IEEE 機器人學報 ,34 (4), 856–869 。

Hopcroft, JE 、Schwartz, JT 與 Sharir, M. (1984) 。論多個獨立物體運動規劃的複雜性 ; 「倉庫管理員問題」的 pspace-hardness 。國際機器人研究雜誌 ,3 (4), 76–88 。

Kornhauser, D. 、Miller, G. 與 Spirakis, P. (1984) 。協調圖上的卵石運動 、排列群的直徑和應用 。 IEEE 計算機科學基礎研討會論文集 ,第 241-250 頁 。

Lam, E. 、Le Bodic, P. 、Harabor, DD 與 Stuckey, PJ (2019) 。多智能體尋路的分支和切割和定價 。

萊頓 ·T. 和肖爾 ·P. (1989) 。極小極大網格匹配的嚴格界限與演算法平均情況分析的應用 。組合 ,9 (2), 161–187 。

Li, J. 、Chen, Z. 、Harabor, D. 、Stuckey, P. 與 Koenig, S. (2021a) 。透過大型鄰域搜尋隨時進行多智能體路徑查找 。國際人工智慧聯合會議 (IJCAI) 。

Li, J. 、Ruml, W. 與 Koenig, S. (2021b) 。 Eecbs :多代理路徑尋找的有界次優搜尋 。 AAAI 人工智慧會議 (AAAI) 會議記錄 。

Li, J. 、Tinka, A. 、Kiesel, S. 、Durham, JW 、Kumar, TS 與 Koenig, S. (2020) 。大型倉庫中的終身多代理路徑查找。

李 Q. 、林 W. 、劉 Z. 和 Prorok, A. (2021) 。用於大規模多機器人路徑規劃的訊息感知圖注意網路。
IEEE 機器人和自動化快報 6 (3) ,
5533–5540 。

LogisticsIQ (2020) 。疫情後 (covid-19) 對倉庫自動化市場的影響按技術、產業、地理劃分 - 預測到 2026 年。
Researchandmarkets.com/r/s6basv 。造訪時間 :2022 年 1 月 5 日。

Luna, RJ 與 Bekris, KE (2011) 。推送與交換 :快速協作尋路並確保完整性。第二十二屆國際人工智慧聯合會議。

Ma, H. 、Harabor, D. 、Stuckey, PJ 、Li, J. 與 Koenig, S. (2019) 。以一致的優先順序進行搜索,以實現多代理路徑
查找。AAAI 人工智慧會議論文集,卷。33,第 7643–7650 頁。

Ma, H. 與 Koenig, S. (2016) 。代理團隊的最佳目標分配和路徑查找。
在美國醫學協會。

Ma, H. 、Kumar, TS 與 Koenig, S. (2017a) 。具有延遲機率的多代理路徑查找。
AAAI 人工智慧會議論文集,卷。31。

Ma, H. 、Li, J. 、Kumar, TKS 與 Koenig, S. (2017b) 。終身多智能體尋路
線上取貨和送貨任務。在美國醫學協會。

梅森, R. (2019) 。發展獲利的線上雜貨物流業務 :探索ocado 的訂購、履行和配送創新。《當代營運與物流》,
第 365–383 頁。施普林格。

奧村, K. (2023) 。Lacam :基於搜尋的演算法,用於快速多智能體尋路。AAAI 人工智慧會議論文集,
卷。37,第 11655–11662 頁。

Okumura, K. 、Machida, M. 、Défago, X. 與 Tamura, Y. (2019) 。具有回溯功能的優先權繼承用於迭代多代理路徑查找。在 IJCAI 中。

Okumura, K. 、Tamura, Y. 與 Défago, X. (2021) 。即時多機器人路徑規劃的迭代精進。2021 年 IEEE/RSJ 智慧機
器人與系統國際會議 (IROS),第 9690–9697 頁。IEEE。

Perron, L. 與 Furnon, V. Or-tools.. <https://developers.google.com/optimization/>。

Poduri, S. 與 Sukhatme, GS (2004) 。移動感測器網路的覆蓋範圍有限。IEEE 國際機器人與自動化會議論文
集。

Preiss, JA 、Hönig, W. 、Sukhatme, GS 和 Ayanian, N. (2017) 。Crazyswarm :大型奈米四軸飛行器群。在 IEEE 國際。會議。機器
人與自動化 (ICRA) 。

Rus, D. 、Donald, B. 與 Jennings, J. (1995) 。使用自主機器人團隊移動家具。IEEE/RSJ 國際智慧機器人與系統會議論文集,第
235–242 頁。

Sartoretti, G. 、Kerr, J. 、Shi, Y. 、Wagner, G. 、Kumar, TS 、Koenig, S. 和 Choset, H. (2019) 。
原始 :透過強化和模仿多主體學習進行尋路。IEEE 機器人和自動化快報 4 (3), 2378–2385。

Sharon, G.、Stern, R.、Felner, A. 與 Sturtevant, NR (2015) 。基於衝突的最佳多智能體尋路搜尋 。人工智慧 , 219 :40-66 。

Sharon, G.、Stern, R.、Goldenberg, M. 與 Felner, A. (2013) 。用於最優多智能體尋路的遞增成本樹搜尋 。人工智慧 ,195 :470-495 。

Shor, PW 與 Yukich, JE (1991) 。最小最大網格匹配和經驗測量 。機率年鑑 ,19 (3), 1338-1348 。

西爾弗 ,D. (2005) 。合作尋路.. Aiide, 1, 117-122.

Stern, R.、Sturtevant, NR、Felner, A.、Koenig, S.、Ma, H.、Walker, TT、Li, J.、Atzmon, D.、Cohen, L.、Kumar, TS 等。 (2019) 。多代理尋路 :定義、變體和基準 。第十二屆組合搜尋年度研討會 。

蘇裡內克 ,P. (2009) 。雙連通圖中多個機器人路徑規劃的新穎方法 。2009 年 IEEE 國際機器人與自動化會議 ,第 10 頁。 3613-3619 。 IEEE 。

蘇裡內克 ,P. (2010) 。多機器人路徑規劃的最佳化變體很棘手 。AAAI 人工智慧會議論文集 ,卷。 24.

蘇裡內克 ,P. (2012) 。透過可滿足性求解 ,在硬設定中實現最佳協作路徑規劃 。環太平洋國際人工智慧會議 , 第 564-576 頁 。施普林格 。

Szegedy, M. 與 Yu, J. (2023) 。魔術方塊表和物件重新排列 。國際 機器人研究雜誌 ,42 (6), 459-472 。

瓦格納 ,G.、喬塞特 ,H. (2015) 。多機器人路徑規劃的亞維擴展 。 人工智慧 ,219 :1-24 。

萬Q.、顧成、孫S.、陳明、黃H.、賈X. (2018) 。動態環境中的終身多智能體路徑尋找 。2018 年第 15 屆控制、自動化、機器人和視覺國際會議 (IARCV) ,第 875-882 頁。 IEEE 。

Wurman, PR、D. Andrea, R. 與 Mountz, M. (2008) 。協調倉庫中數百輛合作自動駕駛車輛 。人工智慧雜誌 ,29 (1) , 9-9 。

於傑 (2015) 。平面圖上最優多機器人路徑規劃的棘手性 。 IEEE 機器人與自動化快報 ,1 (1), 33-40 。

於建 (2018) 。高維網格上的恆定因子時間最優多機器人路由 。 2018 年機器人技術 :科學與系統 。

Yu, J. 與 LaValle, M. (2012) 。圖上的距離最優編隊控制有嚴格的收斂時間保證 。2012 年 IEEE 第 51 屆 IEEE 決策與控制會議 (CDC) ,第 4023-4028 頁。 DOI :10.1109/CDC.2012.6426233 。

Yu, J. 與 LaValle, SM (2013a) 。多代理路徑規劃和網路流 。在演算法中 機器人學基礎 X ,第 157-173 頁 。施普林格 。

Yu, J. 與 LaValle, SM (2013b) 。圖上最優多機器人路徑規劃的結構與難解性 。第二十七屆 AAAI 人工智慧大會。

Yu, J. 與 LaValle, SM (2016) 。圖上的最佳多機器人路徑規劃 :完整的演算法和有效的啟發式 。 IEEE 機器人學 報 ,32 (5), 1163-1177 。